Подготовка к защите лабораторных 2, 3 и 4

Пособие с нуля по вашему репозиторию. Иноземцев Сергей Викторович, ЕТ-216. Дисциплина: «Сбор, анализ и предобработка данных в машинном обучении».

Цель - понимать, что делает код, уметь заново выполнить основные действия и объяснить вывод. Здесь разобраны реальные задания курса и результаты проверенных ноутбуков, а не универсальная шпаргалка с произвольными числами.

Где смотреть	Что изучать
lab2/lab2.ipynb	A: NumPy и статистика; B: 15 заказов; C: 3000 заказов
lab3/lab3.ipynb	Pandas, Matplotlib, Seaborn и интерпретация графиков
lab4/lab4.ipynb	Новорождённые; психологические шкалы; бонус Iris

Как пользоваться

Сначала прочитайте страницы 2-3 и выполните примеры руками. Затем откройте нужный ноутбук, выберите Python-ядро и выполните Restart Kernel and Run All Cells. Читайте блоки кода вместе с выводом. После главы закройте пояснения и решите тренировочные задания.

Маршрут: основы и Pandas - стр. 2-3; лабораторная 2 - стр. 4-10; лабораторная 3 - стр. 11-14; лабораторная 4 - стр. 15-20; общие ошибки - стр. 21; сценарий защиты и самопроверка - стр. 22-23.

Что важно знать о файлах

В каждой лабораторной один ноутбук, README и таблицы. Графики встроены в ноутбук, внешних PNG нет. CSV с результатами могут пересоздаваться при запуске. Исходные XLSX и StudentsPerformance.csv получены из курса. Большой набор заказов сгенерирован и не является реальной статистикой магазина.

Пособие временно лежит в корне репозитория как отдельный PDF для подготовки. Его удаление позже не повлияет на выполнение лабораторных.

1 Основы Python и Jupyter

Ячейка Markdown содержит пояснение, ячейка Code - программу. Shift+Enter выполняет текущую ячейку. Переменные живут в памяти ядра, поэтому запуск ячеек в случайном порядке может давать старые значения или NameError. Restart Kernel очищает память; Run All проверяет, что работа воспроизводится с нуля.

```
x = 10                  # одно число
values = [8, 10, 12]     # список
x = x + 1               # присвоить новое значение
for value in values:    # повторить для каждого элемента
    print(value * 2)

def average(a):         # функция с параметром a
    return sum(a) / len(a)
average(values)         # результат: 10
```

Отступ определяет тело цикла или функции. Знак = присваивает, == сравнивает. Точка обращается к атрибуту или методу: df.shape - свойство, df.head() - вызов метода. Квадратные скобки выбирают элементы, круглые передают аргументы функции.

Объект	Что означает	Пример
ndarray NumPy	Однотипные значения; несколько осей	np.array([1, 2, 3])
Series Pandas	Один столбец с индексом	df["price"]
DataFrame Pandas	Таблица со столбцами и индексом	df[["price", "quantity"]]

Векторная операция применяется сразу ко всему столбцу: df["price"] * df["quantity"]. Это не ручной цикл по строкам. display показывает таблицу, print - текстовое представление. assert проверяет условие и останавливает выполнение при нарушении.

Первый запуск

Окружение создаётся вне репозитория по инструкции README. Нужны numpy, pandas, scipy, matplotlib, seaborn, openpyxl и Jupyter. FileNotFoundError обычно означает неверную рабочую папку или имя файла, а не поломку анализа.

2 Загрузка и проверка таблиц

Одна строка здесь - одно наблюдение, например заказ или ученик. Столбец - признак. До вычислений проверьте единицы, типы, пропуски и смысл кодов: числовой ID не становится измеряемой величиной только потому, что хранится как число.

```
df = pd.read_csv(DATA / "StudentsPerformance.csv")
display(df.head())
print(df.shape)           # (строки, столбцы)
df.info()                 # типы и число непустых значений
display(df.isna().sum())  # пропуски по столбцам
display(df.describe())    # статистики числовых признаков
```

CSV - текстовая таблица с разделителями. XLSX - книга Excel, иногда с несколькими листами: read_excel(..., sheet_name="исходные данные"). index=False в to_csv не добавляет технический индекс как лишний столбец. Пропуск NaN не равен нулю: ноль может быть настоящим измерением.

```
df["price"]                       # Series
df[["price", "quantity"]]         # DataFrame
df.iloc[3:8]                      # позиции 3, 4, 5, 6, 7
df.loc[df["price"] > 2000]        # строки по булевой маске
mask = (df["price"] > 2000) & (df["quantity"] > 3)
df.loc[mask, ["price", "quantity"]]
```

iloc использует позиции, правая граница среза исключается. loc использует метки; правая метка среза обычно включается. & объединяет условия поэлементно, | означает «или», ~ инвертирует маску. Обычные and/or не предназначены для двух целых Series.

Порядок первичного анализа

Сначала загрузить, затем проверить размер и названия, типы, пропуски, дубликаты и диапазоны. Только после этого фильтровать и сравнивать. describe() не объясняет, почему значение необычное; содержательную проверку делает исследователь.

3 Лабораторная 2 А Массивы NumPy

Требуется создать массивы заказов, изучить их размеры, собрать матрицу, выбрать строки и столбцы, различить представление и копию, применить булевы условия. Один индекс во всех трёх массивах должен относиться к одному заказу.

```
delivery = np.array([35, 42, 28, 51, 39, 63, 31, 45])
price = np.array([1200,3500,800,4200,1900,5600,1500,2800])
items = np.array([2, 5, 1, 7, 3, 8, 2, 4])
orders = np.column_stack((delivery, price, items))
print(orders.shape, orders.ndim, orders.size)
# (8, 3), 2, 24
```

Выражение	Смысл
delivery.shape / ndim / size	(8,), одна ось, восемь элементов
orders[0]	Первый заказ: 35 минут, 1200 рублей, 2 товара
orders[:, 0]	Время доставки всех заказов
orders[5, 2]	Число товаров в шестом заказе: 8
orders[2:] / orders[:5, :2]	С третьего заказа до конца / первые пять строк и два признака

Почему нельзя путать view и copy

```
view = orders[:, 0]
view[0] = 1000           # изменится и orders[0, 0]
orders[0, 0] = 35        # восстановить исходное значение
independent = orders[:, 0].copy()
independent[0] = 1000    # orders больше не меняется
```

Срез часто использует ту же память. Поэтому «почистить копию» без .copy() может означать незаметно изменить исходные данные. np.shares_memory проверяет общую память. Массивы разной длины нельзя бездумно усекать: это скрывает потерянные наблюдения.

Маски

delivery > 45 выбирает 51 и 63: два заказа со средним 57 минут. Условие >=45 добавит заказ на 45 минут, их будет три. (price>3000)&(items>4) выбирает заказы на 3500, 4200 и 5600 рублей.

4 Лабораторная 2 А Статистики и связь

Среднее - сумма значений, делённая на число наблюдений. Медиана - середина упорядоченной выборки. Стандартное отклонение описывает типичный масштаб разброса около среднего и имеет единицы исходного признака. Дисперсия выражается в квадрате этих единиц.

```
x = np.array([8, 9, 10, 11, 12])
print(x.mean(), np.median(x))      # 10, 10
bad = np.append(x, 1000)
print(bad.mean(), np.median(bad))  # 175, 10.5
np.std(x, ddof=0)                 # делитель n
np.std(x, ddof=1)                 # делитель n - 1
```

Среднее сильно изменилось из-за одного экстремума, медиана почти не изменилась. Это не делает среднее «неправильным»: для общей суммы затрат редкая большая задержка тоже важна. Выбор показателя зависит от вопроса.

Процентили и SLA

p90 - порог, ниже которого примерно 90% наблюдений. При моделировании нормального распределения со средним 30 и σ=5, seed=42 и n=1000 получены p90=36.53, p95=38.38, p99=41.58 минуты. Для требования «90% доставок не дольше 40 минут» условие p90<=40 выполнено в симуляции. Это не доказывает качество реальной службы доставки.

У служб A=[28,29,30,31,32] и B=[15,20,30,40,45] среднее и медиана равны 30. А предсказуемее: ниже стандартное отклонение и верхние процентили. Среднего недостаточно для описания качества.

Корреляция

```
r = np.corrcoef(items, delivery)[0, 1]
# -1 <= r <= 1; коэффициент Пирсона отражает линейную связь
```

Положительное r означает, что большие значения одного признака обычно сопровождаются большими значениями другого. r около нуля не исключает нелинейной связи. Корреляция не доказывает причинность: общий фактор может влиять на оба признака. В задании генерация времени через число товаров создаёт связь специально.

5 Лабораторная 2 A Bootstrap и гипотезы

Bootstrap оценивает изменчивость статистики с помощью повторного выбора наблюдений из имеющейся выборки. Выбор с возвращением означает, что один элемент может встретиться несколько раз в одной новой выборке.

```
x = np.array([28, 31, 29, 45, 32, 30])
np.random.seed(42)
means = np.empty(5000)
for i in range(len(means)):
    sample = np.random.choice(x, size=len(x), replace=True)
    means[i] = sample.mean()
ci = np.quantile(means, [0.025, 0.975])
```

Среднее исходной выборки равно 32.5 минуты. Для каждой из 5000 реплик рассчитывается новое среднее, затем берутся крайние 2.5% и 97.5%. Без возвращения выбор всех шести элементов дал бы только перестановки с одинаковым средним. При n=6 результат нестабилен: новые данные могут заметно изменить интервал.

95% доверие относится к процедуре: при многократном повторении эксперимента примерно 95% построенных таким способом интервалов должны накрывать параметр при выполнении условий метода. Нельзя говорить, что конкретное фиксированное истинное среднее случайно с вероятностью 95% находится в уже построенном интервале.

Алгоритм ускорения доставки

Пусть Δ=μB-μA. H0: Δ>=0, уменьшения среднего нет. H1: Δ<0, новый алгоритм уменьшает среднее. При вычислении одностороннего критерия используется граничный случай Δ=0. Альтернативу выбирают до просмотра результата.

Понятие	Правильное объяснение
p-value	Вероятность при H0 и предпосылках получить не менее экстремальную статистику в направлении альтернативы
Ошибка I рода	Объявить улучшение, которого нет
Ошибка II рода	Не обнаружить существующее улучшение
p=0.001 при α=0.05	Статистическое свидетельство против H0; не гарантия большой или выгодной разницы

Экономия трёх секунд может быть статистически обнаружимой, но не оправдывать расходы. Для решения отдельно нужны величина эффекта, интервал, стабильность сегментов и практически полезный порог. p-value не является вероятностью истинности H0.

6 Лабораторная 2 B Конвейер для 15 заказов

Требуется создать таблицу из условия, сохранить CSV, загрузить обратно, исследовать структуру, выполнить выборку, фильтрацию, группировку и показать влияние крупного заказа. Главная идея - последовательность действий, а не отдельный вызов describe().

```
df = pd.DataFrame(raw_data)
df.to_csv(DATA / "online_store_orders.csv", index=False)
store_df = pd.read_csv(DATA / "online_store_orders.csv")
print(store_df.shape)
display(store_df.isna().sum())
selected = store_df.loc[
    (store_df.order_sum > 2000) & (store_df.rating == 5)
]
store_df["is_high_value"] = store_df.order_sum > 3000
summary = store_df.groupby("channel").order_sum.mean()
```

Проверка	Результат в ноутбуке
Размер	15 строк и 5 столбцов до добавления нового признака
Пропуски	3 значения delivery_time
Фильтр сумма>2000 и рейтинг=5	Заказ 1009
Доставка	Среднее 39.58, медиана 37.50 минуты по непустым значениям
Сумма по каналам, среднее	marketplace: 13775.00; site: 1816.67; app: 1800.00 рублей
Заказы дороже 3000	4 заказа

groupby("channel") разделяет строки по каналу, mean() вычисляет среднюю сумму внутри каждой группы. value_counts() считает частоты значений, а не их денежную сумму. У count() пропуски не учитываются; size() считает строки.

Почему marketplace выглядит необычно

В этом канале есть заказ на 45000 рублей. Он повышает среднее и растягивает ось гистограммы. Нельзя на этом основании сказать, что типичный заказ marketplace лучше: нужно посмотреть медиану, число заказов и распределение. Экстремум не удаляется только потому, что мешает красивому графику.

В этой части пропуски времени не заменяются на 0: mean/median пропускают NaN. На защите обязательно поясните, что вывод относится только к наблюдениям с известным временем.

7 Лабораторная 2 С Подготовка 3000 заказов

Задание требует самостоятельно сгенерировать 3000 заказов с разными городами, категориями, платежами и статусами, добавить около 30 пропусков возраста и провести анализ. Seed=2024 фиксирует последовательность генератора при одном и том же коде.

Строка означает заказ, а не уникального клиента: customer_id может повторяться. nunique() считает уникальных клиентов. Частоты возраста по заказам - не то же самое, что возрастное распределение уникальных людей.

```
df["order_date"] = pd.to_datetime(df["order_date"])
df["year"] = df.order_date.dt.year
df["month"] = df.order_date.dt.month
df["revenue"] = df.price * df.quantity * (1 - df.discount)
df["profit"] = df.revenue - df.cost
df["is_real_sale"] = df.status.eq("Доставлен")
df["age"] = df.age.fillna(df.age.median())
real = df.loc[df.is_real_sale].copy()
```

Проверь единицы на простом заказе

Цена 1000 рублей за товар, количество 3, скидка 0.2: revenue=1000×3×0.8=2400 рублей. Если cost=2500 рублей за весь заказ, profit=-100. В этом коде cost уже включает весь заказ; повторно умножать его на количество нельзя. Скидка 20% записывается 0.2, а не 20.

Пропуски и возрастные интервалы

В age ровно 30 NaN; медиана рассчитывается по известным возрастам. fillna заполняет только пропуски, а не все значения. Такой способ прост и устойчив к экстремумам, но уменьшает вариативность и может искажать группы. В задаче это учебная обработка, а не универсальный лучший метод.

```
df["age_group"] = pd.cut(
    df.age, bins=[0, 18, 30, 45, 60, 100],
    labels=["до 18", "18-30", "31-45", "46-60", "60+"]
)
```

При right=True границы соответствуют (0,18], (18,30] и т.д. Поэтому метка «до 18» в исходном коде включает и 18 лет: на защите называйте точный интервал, а не только его условную подпись.

8 Лабораторная 2 С Фильтры и группировки

После подготовки задайте вопрос: нужны все заказы или только доставленные? Выручка всех заказов показана по условию, фактическая считается отдельно по real. Возвраты и отмены исключены из этого упрощённого расчёта реализованных продаж.

```
filtered = df.loc[
    df.city.eq("Москва") & (df.revenue > 5000)
]
summary = df.groupby("category").agg(
    orders=("order_id", "count"),
    revenue=("revenue", "sum"),
    avg_revenue=("revenue", "mean"),
    profit=("profit", "sum")
)
actual = real.groupby("category").revenue.sum()
vip_share = real.loc[real.is_vip, "revenue"].sum() / real.revenue.sum()
```

agg позволяет одновременно считать несколько статистик с понятными именами. groupby(["category","city"]) создаёт комбинации категорий и городов. unstack переносит один уровень индекса в столбцы и превращает результат в сводную таблицу.

Показатель	Полученный результат
Заказы / доставленные	3000 / 2403
Фактическая выручка	19 170 545.94 рублей
Средняя выручка доставленного заказа	7977.76 рублей
Максимум / минимум выручки категорий	Одежда / Дом
Город с максимальным числом заказов	Казань
Доля VIP в фактической выручке	Около 19.0%

Как читать девять визуализаций

Показаны распределения возраста, выручки и скидки, возраст VIP и обычных клиентов, категории, города, возрастные группы, статусы и месячная выручка. Гистограмма отвечает о распределении чисел; bar - о категориях; временная линия - об изменении во времени. Для месяцев используется период год-месяц, чтобы январь 2023 не смешался с январём 2024.

Разница среднего чека между скидочными группами не доказывает эффект скидки: группы различаются составом товаров, ценами и количеством. Синтетические числа описывают этот набор, а не весь рынок.

9 Лабораторная 2 Вопросы и упражнения

Что показать на экране

В lab2.ipynb найдите по заголовкам A, B и C нужную часть. Покажите изменение исходного массива через view, один булев фильтр, сводку groupby, обработку пропусков и таблицу фактической выручки. Объясните каждую выбранную строку кода своими словами.

Вопрос преподавателя	Короткий ответ
Почему нужен seed?	Чтобы воспроизвести генерацию при том же алгоритме; это не делает данные реальными
Почему mean и median различаются?	Среднее чувствительно к крупным наблюдениям и асимметрии
Почему нужен .copy()?	Чтобы изменения выбранной таблицы/массива не затрагивали исходник через общую память
Сумма revenue равна фактической выручке?	Нет: сначала нужно выбрать доставленные заказы
Что означает p90?	Примерно 90% значений не превосходят этот порог
Зачем Bootstrap с возвращением?	Чтобы состав реплик и статистика действительно менялись
p<0.05 означает выгодное решение?	Нет: практическая величина эффекта и затраты оцениваются отдельно

Сделайте без подсказки

1. Из 15 заказов выберите app и сумму больше 2000. Сначала предскажите смысл маски, затем проверьте результат. 2. В большом наборе посчитайте среднюю фактическую выручку по городам. 3. Для x=[10,10,10,100] найдите среднее и медиану. 4. Объясните, почему без возвращения все bootstrap-реплики полной выборки имеют одно среднее.

Проверка подхода

```
store_df.loc[store_df.channel.eq("app") & (store_df.order_sum > 2000)]
real.groupby("city").revenue.mean()
# Для [10,10,10,100]: mean=32.5, median=10.
# Без возвращения меняется порядок, но не набор значений.
```

Учитесь не заучивать готовое число, а находить соответствующую таблицу и объяснять знаменатель, фильтр и единицы измерения.

10 Лабораторная 3 Что требуется построить

Данные StudentsPerformance.csv: 1000 учеников, 8 признаков, включая оценки математики, чтения и письма. Сначала проверить структуру, пропуски и допустимый диапазон 0-100. В данных 0 пропусков и 0 полных совпадений строк.

Инструмент	Требование задания	Какую мысль объяснить
Pandas	Bar образования родителей; pie race/ethnicity; гистограммы числовых признаков	Категории считают частоты, гистограммы разбивают числовую ось на интервалы
Matplotlib	Одна композиция 3×2 из шести панелей	Фигура содержит отдельные оси; каждой задаются данные и подписи
Seaborn	Два pairplot и heatmap корреляций	Парные связи, распределения, различия групп по цвету

Код загрузки

```
df = pd.read_csv(DATA / "StudentsPerformance.csv")
scores = ["math score", "reading score", "writing score"]
print(df.shape)
display(df.isna().sum())
display(df[scores].describe())
df["parental level of education"].value_counts().plot.bar()
```

value_counts возвращает количество учеников в каждой категории. Для круговой диаграммы категории race/ethnicity нужны именно количества, а не суммы строковых значений. Для гистограмм выбираются числовые оценки.

В методичке есть опечатки: фактическое имя файла StudentsPerformance.csv, а значение пола male. Если написать mail, выборка будет пустой; это не означает, что в данных нет юношей.

График должен отвечать на вопрос

Подпишите оси и единицы, проверьте легенду и масштаб. Красивый цвет сам по себе не является выводом. На защите назовите оси, наблюдаемую закономерность и ограничение интерпретации.

11 Лабораторная 3 Matplotlib по шагам

Figure - весь рисунок, Axes - отдельная область графика. В коде fig.add_subplot(321) означает 3 строки, 2 столбца, первая панель. Номера продолжаются до 326. Не путайте эти номера с индексами массива axes, который начинается с нуля.

```
fig = plt.figure(figsize=(16, 17))
ax = fig.add_subplot(321)
x = np.linspace(-2*np.pi, 2*np.pi, 500)
ax.plot(x, np.cos(2*x), color="yellow", label="cos(2x)")
ax.plot(x, 2*np.cos(x), color="red", label="2cos(x)")
ax.grid(True)
ax.legend()
```

Панель	Что делает код
1	Жёлтый cos(2x), красный 2cos(x), диапазон от -2π до 2π и сетка
2	Boxplot math score: медиана, квартили, усы и точки-кандидаты в выбросы
3	Частоты race/ethnicity: столбцы и линия на одних осях
4	Текст HELLO!!! и скрытые оси
5	3D scatter: математика, чтение и письмо; нужна projection="3d"
6	Pie с процентами образования родителей только среди male

Что означает np.linspace

Он создаёт 500 равномерно расположенных x между границами. cos(2x) меняет частоту, 2cos(x) - амплитуду. Это демонстрационные математические функции, не модель успеваемости учеников.

Как устроена фильтрация для pie

```
boys = df.loc[df.gender.eq("male")]
counts = boys["parental level of education"].value_counts()
counts.plot.pie(autopct="%1.1f%%")
```

Знаменатель долей здесь - число юношей в выборке, не число всех учеников. Проверка знаменателя важнее декоративного оформления.

12 Лабораторная 3 Seaborn и реальные выводы

```
sns.pairplot(df[scores], diag_kind="hist")
sns.pairplot(df[scores + ["gender"]],
             hue="gender", diag_kind="kde")
sns.heatmap(df[scores].corr(), annot=True,
            vmin=-1, vmax=1, cmap="coolwarm")
```

В pairplot каждая вне-диагональная панель - scatter двух признаков. Диагональ показывает распределение одного признака: hist или KDE. KDE - сглаженная оценка плотности, а не вероятность ровно одного значения. hue раскрашивает известные группы; никакой кластеризации алгоритмом здесь нет.

Тепловая карта

Корреляционная матрица симметрична, на диагонали 1. Шкала от -1 до 1 фиксирована. Самая сильная линейная связь - чтение и письмо: r≈0.955. Это не доказательство того, что увеличение балла по чтению само вызывает рост письма.

Boxplot и IQR

```
q1, q3 = df["math score"].quantile([0.25, 0.75])
iqr = q3 - q1
low, high = q1 - 1.5*iqr, q3 + 1.5*iqr
outliers = df.loc[(df["math score"] < low) |
                  (df["math score"] > high)]
```

Получены границы 27 и 107, найдено 8 низких экстремальных оценок. Верхняя граница может быть выше максимально возможных 100 - это расчётное правило, а не ошибка. Низкие допустимые баллы не удаляются автоматически.

Группа	Математика	Чтение	Письмо
female	63.63	72.61	72.47
male	68.73	65.47	63.31
Подготовка completed	69.70	73.89	74.42
Подготовка none	64.08	66.53	64.50

Это наблюдаемые средние данной выборки. Без контроля других факторов нельзя утверждать причинное влияние пола, происхождения или прохождения подготовки.

13 Лабораторная 3 Защита и практика

Объяснение за одну минуту

«Я загрузил данные учеников, проверил пропуски и диапазон оценок. Сначала показал распределения категорий и баллов через Pandas. Затем собрал шесть разных панелей Matplotlib. Через Seaborn сравнил парные связи и группы. Чтение и письмо имеют сильную положительную корреляцию, но причинность из этого не следует. IQR отметил восемь низких оценок математики, которые остаются допустимыми наблюдениями».

Вопрос	Ответ
Bar или histogram?	Bar - отдельные категории; histogram - интервалы числового признака
Зачем три библиотеки?	Pandas даёт краткую обёртку, Matplotlib управляет рисунком, Seaborn удобен для статистических графиков
Что такое усы boxplot?	Границы наблюдений внутри правила 1.5 IQR; не всегда минимум и максимум всей выборки
hue - это поиск кластеров?	Нет, цвет задаётся уже существующим признаком gender
Почему не выкинул восемь строк?	Экстремальность по IQR не доказывает ошибку измерения
Может r≈0 означать отсутствие связи?	Только линейной; нелинейная зависимость может сохраняться

Сделайте самостоятельно

1. Выведите средний math score по test preparation course. 2. Постройте гистограмму reading score и подпишите ось частоты. 3. Выберите только male и проверьте, что выборка непустая. 4. Найдите пару оценок с самой сильной корреляцией вне диагонали.

```
df.groupby("test preparation course")["math score"].mean()
df["reading score"].plot.hist(bins=15)
boys = df.loc[df.gender.eq("male")]
assert len(boys) > 0
corr = df[scores].corr()
# Не выбирайте диагональные единицы как «самую сильную пару».
```

Перед защитой найдите эти действия в собственном ноутбуке по заголовкам, а не пытайтесь воспроизводить весь файл по памяти.

14 Лабораторная 4 Как выбрать критерий

Сначала сформулируйте вопрос и единицу наблюдения, затем выбирайте метод. В этих заданиях группы состоят из разных людей: это независимые выборки. Измерения одного и того же человека до и после были бы парными, но здесь такой структуры нет.

Вопрос	H0	Метод в работе
Похоже ли распределение на нормальное?	Наблюдения согласуются с нормальным распределением	Графики, Shapiro; в бонусе χ^2
Отличаются ли средние двух независимых групп?	$\mu A = \mu B$	Двусторонний Welch t-test
Где различие выражено сильнее?	Не отдельная H0, а оценка величины	Разность, 95% ДИ и Cohen d

```
x = frame.loc[frame[group].eq(a), column].dropna()
y = frame.loc[frame[group].eq(b), column].dropna()
t, p = stats.ttest_ind(x, y, equal_var=False)
# alternative по умолчанию two-sided
```

equal_var=False выбирает критерий Уэлча. Он не требует одинаковых дисперсий, но не отменяет требования независимости и разумной формы распределений. При очень малых выборках, сильных выбросах и некоторых дискретных шкалах интерпретация требует осторожности.

Статистика t и p-value

$t=(mean_A-mean_B)/sqrt(s_A^2/n_A+s_B^2/n_B)$. Знаменатель - стандартная ошибка разности, а не стандартное отклонение всех людей. Знак t зависит от порядка групп; двустороннее p при их перестановке не меняется.

При $\alpha=0.05$ и $p<\alpha$ отвергаем H0 о равенстве средних. При $p>=\alpha$ говорим «нет достаточных оснований отвергнуть H0», а не «средние доказанно одинаковы». Нормальность и равенство средних - разные гипотезы и разные тесты.

15 Лабораторная 4 А Данные новорождённых

В файле «Пренатальная диагностика.xlsx» выбирается лист «исходные данные». 1050 наблюдений: 577 мальчиков и 473 девочки. Столбец pol(1-м, 0-д) задаёт группы 1 и 0. Числовые показатели включают возраст, срок, параметры обследования, рост и вес.

```
birth = pd.read_excel(DATA / "Пренатальная диагностика.xlsx",
                      sheet_name="исходные данные")
display(birth["pol(1-м, 0-д)"].value_counts())
birth["ИМТ"] = (birth.ves / 1000) / (birth.rost / 100)**2
num = [c for c in birth.select_dtypes("number").columns
       if c != "pol(1-м, 0-д)"]
descr = birth[num].describe().T
descr["range"] = birth[num].max() - birth[num].min()
```

Вес дан в граммах, рост в сантиметрах. ИМТ=кг/м²: для 3500 г и 50 см получится $3.5/0.5^2=14$. Если забыть переводы единиц, получится другая величина. Учебное вычисление не используется здесь для клинических рекомендаций.

Что сравнить с нормальным распределением

Для каждого числового показателя построены гистограмма с KDE, рассчитаны асимметрия и эксцесс, выполнен Shapiro. Код пола исключён: распределение бинарного кода не является непрерывной нормальной величиной.

```
x = birth["rost"].dropna()
sns.histplot(x, kde=True)
print(stats.skew(x, bias=False))
print(stats.kurtosis(x, bias=False))  # эксцесс, не 3
W, p = stats.shapiro(x)
```

Для нормальной генеральной совокупности асимметрия и эксцесс равны нулю, среднее равно медиане. Выборочные оценки не обязаны точно совпадать с ними. Во всех семи проверенных показателях Shapiro дал $p<0.05$; при $n=1050$ тест чувствителен даже к небольшим отклонениям.

Отрицательный вывод по Shapiro не означает, что любые сравнения средних запрещены. Нужно оценить графики, выбросы, независимость и объём групп; здесь Welch использует большие независимые группы, а ограничения оговорены.

16 Лабораторная 4 А Результаты сравнения

В таблице А - мальчики, В - девочки. Проверяются рост, вес и ИМТ. Для каждого показателя H0: μA=μB; H1: μA≠μB. Двусторонний критерий выбран заранее.

Показатель	Среднее A / B	A-B	p	p Holm
rost	52.002 / 51.328	0.674	1.44e-07	2.88e-07
ves	3497.456 / 3360.541	136.915	1.76e-08	5.29e-08
ИМТ	12.906 / 12.737	0.169	0.00695	0.00695

Показатель	95% ДИ разности A-B	Cohen d
rost	[0.424; 0.924]	0.327
ves	[89.600; 184.229]	0.348
ИМТ	[0.046; 0.292]	0.167

Все три p_Holm меньше 0.05. В данной выборке мальчики в среднем выше примерно на 0.674 см и тяжелее на 136.915 г; разность ИМТ около 0.169. Интервалы разности не пересекают ноль. Это описание средних групп, а не правило для каждого ребёнка.

Что означают три разных числа

Разность средних выражается в исходных единицах. p-value оценивает статистическое свидетельство против H0. Cohen d делит разность на объединённое стандартное отклонение и выражает величину в безразмерной шкале. Маленькое p может сочетаться с небольшим d при большой выборке.

Доверительный интервал показывает неопределённость оценки разности в рамках метода. Используется t-квантиль со степенями свободы Уэлча. Эти интервалы обычные 95% для каждого сравнения; поправка Holm в таблице корректирует p-value, а не превращает интервалы в одновременные.

Что сказать в выводе

«В выбранных данных различия средних обнаружены по всем трём признакам, в том числе после Holm. Я отдельно оценил величину различий и интервалы. Вывод ограничен выборкой и предпосылками анализа и не является медицинским заключением».

17 Лабораторная 4 В Психологические шкалы

В «Психологи.xlsx» 46 учащихся: 23 юноши и 23 девушки. Имена столбцов и код пола очищаются от пробелов, пол приводится к нижнему регистру. Номер учащегося и код профиля ВУЗа исключены из измеряемых психологических шкал. Анализируются 15 показателей.

Показатель	t	p	p Holm
экстраверсия- интроверсия	-3.444	0.0013	0.0197
скрытые фигуры	-2.011	0.0506	0.7090
арифметика	1.669	0.1027	1.0000
нейротизм	1.615	0.1136	1.0000
числовые ряды	1.602	0.1165	1.0000
заучивание слов	-1.536	0.1321	1.0000
средняя отметка	-1.490	0.1435	1.0000
осведомленность	-1.473	0.1481	1.0000
исключение изображений	-1.357	0.1826	1.0000
геометрическое сложение	1.337	0.1882	1.0000
аналогии	0.919	0.3632	1.0000
пропущенные слова	-0.622	0.5373	1.0000
понятливость	-0.525	0.6019	1.0000
умозаключения	0.302	0.7640	1.0000
средний IQ	-0.166	0.8692	1.0000

При α=0.05 значима только «экстраверсия- интроверсия», в том числе после Holm: t≈-3.444, p≈0.001313. A - юноши: среднее 11.565; B - девушки: 14.609. Знак разности отрицателен из-за выбранного порядка групп.

По |d| самая большая разность здесь у этой же шкалы: d≈-1.016. Наименьшая - средний IQ: d≈-0.049, p≈0.869. Не путайте минимальное p с универсальным определением самого большого эффекта: здесь эти ранжирования проверяются отдельно.

Шкала «скрытые фигуры» имеет p≈0.05065: это немного выше порога, значит H0 не отвергается. Округлять до 0.05 и объявлять значимость нельзя. Другие факторы, например класс и профиль, могут влиять на сравнение; причинный эффект пола не установлен.

18 Лабораторная 4 С Бонус Iris и χ²

Требуется загрузить Iris.xlsx, убрать номер и название сорта из числовой таблицы, перевести четыре признака, задать индексы 1-150 и написать функцию Gauss. Исходную таблицу с названием сорта нужно сохранить отдельно для последующей группировки.

Gauss печатает объём выборки, среднее, медиану, асимметрию и эксцесс, строит гистограмму/KDE, формулирует гипотезы, вычисляет χ² и p-value и возвращает p. H0: данные согласуются с нормальным распределением, H1: не согласуются.

```
mu, sigma = x.mean(), x.std(ddof=0)
k = min(8, len(x) // 10)
edges = stats.norm.ppf(np.linspace(0, 1, k + 1),
                       loc=mu, scale=sigma)
observed, _ = np.histogram(x, bins=edges)
expected = np.full(k, len(x) / k)
chi2, p = stats.chisquare(observed, expected, ddof=2)
```

Границы - квантили подогнанной нормали, крайние равны -∞ и +∞. Поэтому теоретические вероятности интервалов одинаковы, а ожидаемая частота равна n/k. $\chi^2=\text{sum}((O-E)^2/E)$. Число степеней свободы k-1-2=k-3: из данных оценены μ и σ. Реализация использует учебное асимптотическое приближение; результат зависит от разбиения и объёма выборки.

Выборка / признак	p	Вывод при 0.05
Все 150: ширина лепестка	1.895e-11	H0 отклонена
Все 150: длина лепестка	9.219e-20	H0 отклонена; минимальное p
Все 150: ширина чашелистика	0.1208	H0 не отклонена
Все 150: длина чашелистика	0.0590	H0 не отклонена

Для n=150 k=8, E=18.75; для n=50 k=5, E=10. Малые ожидаемые частоты сделали бы приближение χ² ненадёжным, поэтому их нельзя игнорировать.

19 Лабораторная 4 С Сорта и ограничения

Самый малый p среди четырёх признаков получен для длины лепестка. Далее именно этот признак проверяется для каждого сорта и для двух объединений. Значения Species_name сначала очищаются .str.strip(): пробелы могли бы дать пустой результат фильтра.

Группа длины лепестка	n	p χ^2	Вывод
Setosa	50	0.1108	H0 не отклонена
Verginica (имя в файле)	50	0.5488	H0 не отклонена
Versicolor	50	0.1496	H0 не отклонена
Мелкие: Setosa	50	0.1108	H0 не отклонена
Крупные: два остальных сорта	100	0.4208	H0 не отклонена

Объединение всех сортов может давать распределение со сложной формой, хотя внутри групп тест не отклоняет нормальность. Средние разных сортов разнесены; смесь нормальных распределений вообще не обязана быть нормальной.

В этих данных объединение двух крупных сортов не отклонено тестом. Это не общий закон для любых смесей и не доказательство идеальной нормальности. Мощность и выбранные интервалы влияют на результат.

Чего нельзя говорить

«Раз p>0.05, нормальность доказана» - неверно. «Наибольшее p означает самый нормальный сорт» - слишком сильное утверждение: p зависит от n и метода. «Iris нужен для обучения классификатора» - не в этой задаче: здесь изучается нормальность, модель машинного обучения не строится.

Как объяснить функцию

Покажите входной одномерный массив, удаление NaN, оценку μ и σ, интервалы и две частоты. Затем найдите строку chisquare и объясните ddof=2. Завершите формулировкой «при данном α H0 отклонена / не отклонена», а не безусловным утверждением о распределении.

20 Общие ошибки статистической интерпретации

Ошибка	Как правильно
p - вероятность, что H0 верна	p рассчитывается условно при H0 и предпосылках
p>=0.05 доказывает равенство	Не обнаружено достаточных свидетельств различия
Все p одинаковы по смыслу	Shapiro/χ^2 проверяют форму, Welch проверяет средние
Ненормальность запрещает любой t-тест	Важны размер групп, независимость, выбросы и устойчивость метода
Welch исправляет любые данные	Он учитывает неравенство дисперсий, но не зависимость наблюдений и не все проблемы формы
Значимость равна большому эффекту	p, разность, ДИ и d отвечают на разные вопросы
Десятки проверок не меняют риск	Без поправки возрастает вероятность хотя бы одной ошибки I рода
Отрицательный d - ошибка расчёта	Это направление A-B; |d| характеризует величину

Как работает Holm

Для m тестов отсортируйте p по возрастанию. Умножьте первое на m, второе на m-1 и так далее. Скорректированные значения не должны уменьшаться по этому порядку: берётся накопительный максимум, результат ограничивается единицей. Затем верните исходный порядок показателей.

У психологических шкал m=15: минимальное p≈0.001313 умножается на 15 и даёт около 0.01970, то есть результат остаётся значимым. Для новорождённых семейство состоит из трёх сравнений. Код выводит исходные и скорректированные p отдельно.

Shapiro для психологических групп проверяется по каждой группе, но это не автоматическая команда «выбрать тест только по p нормальности». При 23 наблюдениях тест может не замечать существенные отклонения. Содержательный анализ и графики обязательны.

Повторяющиеся клиенты в заказах, скрытые группировки учеников и различия профилей - примеры зависимости или смешивания, которые нельзя устранить одной красивой диаграммой или одним p-value.

21 Как пройти защиту по каждому ноутбуку

Общий порядок демонстрации

1. Назвать вопрос и данные. 2. Показать загрузку и проверки качества. 3. Найти основной метод и объяснить параметры. 4. Показать результат с единицами и группами. 5. Сформулировать ограниченный вывод. 6. Уметь изменить одно условие и повторить расчёт.

Лабораторная 2

«Я прошёл путь от массивов к таблицам заказов. На NumPy показал индексацию, маски, влияние выброса, процентили и bootstrap. На 15 заказах проверил пропуски и группировки. Затем с seed=2024 создал 3000 заказов, обработал возраст, посчитал выручку и прибыль. Фактические показатели ограничены доставленными заказами; это учебная симуляция».

Лабораторная 3

«Я исследовал распределения и связи оценок. Через Pandas построил базовые диаграммы, через Matplotlib - сетку 3×2, через Seaborn - pairplot и heatmap. Нашёл 8 низких значений математики по IQR и сильную связь чтения с письмом. Я не объявляю экстремумы ошибками и не вывожу причинность из корреляции».

Лабораторная 4

«Я сформулировал H0 и H1, проверил форму данных и сравнил независимые группы критерием Уэлча. Для новорождённых различия найдены по трём признакам; для 15 психологических шкал - только по экстраверсии-интроверсии после Holm. Отдельно показал разности, интервалы и d. В бонусе проверил Iris через χ^2 с учётом двух оценённых параметров».

Если забыл число или команду

Не придумывайте результат. Найдите его в выводе ячейки, прочитайте подпись столбца и укажите, как он получен. Хороший ответ объясняет принцип и показывает способ проверки. Нужно отличать то, что реально вычислено, от дополнительной гипотезы.

Подготовка: сначала самостоятельно повторить базовые операции, затем объяснить код вслух, затем решить задания на следующей странице без чтения готовых решений. Удаление PDF позже не удалит ноутбуки и таблицы.

22 Итоговая самопроверка и ответы

Задача	Ответ и ход мысли
Цена 2000, количество 2, скидка 0.25, cost=2600	revenue=2000×2×0.75=3000; profit=400; cost дан за весь заказ
iloc[2:5] выбирает какие позиции?	2, 3, 4. Это третья, четвёртая и пятая строки
У [1,2,3,100] среднее и медиана?	26.5 и 2.5; экстремум сдвигает среднее
Можно заменить неизвестное время доставки на 0?	Без содержательного обоснования нет: это означает мгновенную доставку и меняет статистику
Welch p=0.051, α=0.05	H0 не отвергается; не округлять для изменения решения
Разность A-B=-3 и ДИ [-5,-1]	A в среднем ниже B; обычный 95% ДИ разности не пересекает ноль
Shapiro p=0.2	Не найдено достаточно оснований отвергнуть нормальность, но она не доказана
χ^2: k=8 и два оценённых параметра	df=8-1-2=5
Зачем хранить сорта Iris до удаления?	Чтобы после анализа объединённой таблицы сравнить группы
CSV загрузился с Unnamed: 0	Вероятно, сохранён индекс; использовать to_csv(index=False)

Проверка готовности

Без подсказки объясните строку фильтра с двумя условиями, groupby().agg(), формулу выручки, назначение seed, смысл p-value и equal_var=False. На графике назовите оси и не делайте причинных утверждений. Если эти действия получаются, переходите к устной демонстрации своего ноутбука.

Основания пособия

Задания курса edu.susu.ru (course id 218588): приложение NumPy «Лаба 1 (ч.1.4)», две части лабораторной 2, «Лб 3», «ЛР 4_1 Гипотезы», «ЛР 4_2 Т-тесты», бонус Iris. Числа сверены с сохранёнными вычислениями lab2.ipynb, lab3.ipynb, lab4.ipynb и таблицами результатов. Полный запуск трёх обновлённых ноутбуков выполнен без ошибок в новых Python-ядрах.

Этот текст помогает разобраться в работе, но не заменяет самостоятельный запуск и объяснение кода. Статистические выводы относятся к учебным данным и выбранным предпосылкам.